COMP3670 概念速查表 正面：学习、概率、泛化与模型

公式不是终点：先问“对象是什么、平均在哪里、复杂度由谁控制?”

1. 机器学习到底在做什么？

归纳学习：从有限样本发现规律，并希望它在未见数据上仍成立。算法只是“从候选规则中选一个”的工具；真正的模型还包括数据假设、假设集合和损失。

三类学习

- 监督学习：观测 (x_i, y_i)；分类的 Y 离散，回归的 Y 连续。
- 无监督学习：只有 x_i；寻找聚类、低维结构或密度。
- 强化学习：状态 $\to$ 动作 $\to$ 奖励；学习最大化累计奖励的策略。

监督学习的四个核心对象：

$$D = \{(x_i, y_i)\}_{i=1}^N, \quad f^* : \mathcal{X} \to \mathcal{Y},$$
$$\mathcal{H} = \{h\}, \quad \mathcal{A} : D \mapsto \hat{h}$$

目标函数 f^* 是现象允许的最佳预测；**假设集** $\mathcal{H}$ 是学习前允许考虑的规则；**学习算法** $\mathcal{A}$ 用数据选出 $\hat{h}$。

关键区分：训练误差小只是“解释样本”，泛化误差小才是“学到现象”。能拟合一切的模型不可证伪，也最容易过拟合。

2. 损失、经验风险与真正风险

损失 $\ell((x, y), h)$ 衡量一次预测的代价。

- 二分类：$\ell = \mathbf{1}\{h(x) \neq y\}$。
- 回归：$\ell = (h(x) - y)^2$。
- 概率预测：交叉熵 $-y \log \eta(x) - (1 - y) \log(1 - \eta(x))$。

$$E_{\text{in}}(h) = \frac{1}{N} \sum_{i=1}^N \ell((x_i, y_i), h),$$

$$E_{\text{out}}(h) = \mathbb{E}_{(X,Y)\sim P}[\ell((X, Y), h)].$$

$\Rightarrow$ E_{in} 是样本平均，可计算；E_{out} 是对未知总体的平均，才是最终目标。

ERM（经验风险最小化）

$$\hat{h} = \arg\min_{h \in \mathcal{H}} E_{\text{in}}(h).$$

ERM 只负责在 $\mathcal{H}$ 内找训练表现最好的规则；它不自动保证泛化。

3. 概率语言：随机性来自哪里？

随机变量把随机结果映成数；分布描述可能取值及其概率。离散型用概率质量，连续型用密度（点概率通常为 0，区间概率是积分）。

$$\mathbb{E}[X] = \sum_x x P(X = x) \quad \text{（离散）},$$

$$\mathbb{E}[X] = \int x p(x)\, dx \quad \text{（连续）},$$

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2].$$

条件分布 $P(Y \mid X = x)$：知道特征后，对标签还剩多少不确定性。**独立**表示联合分布可分解；i.i.d. 样本意味着每个观测独立且来自同一 P。

不要混淆：f^* 并不必然把每个样本预测正确；噪声存在时，同一个 x 可对应不同 y。

4. Bayes 最优规则：理论下限

二分类令 $\eta(x) = P(Y = 1 \mid X = x)$。在两类错误代价相同时，

$$f^*(x) = \mathbf{1}\{\eta(x) > 1/2\}.$$

$\Rightarrow$ 选择条件概率更大的类别；它逐点最优，因此总体也最优。若错误代价不同，阈值不再是 $1/2$。

平方损失下，

$$f^*(x) = \mathbb{E}[Y \mid X = x],$$
$$E_{\text{out}}(f^*) = \mathbb{E}[\text{Var}(Y \mid X)].$$

后式是**不可约误差**：即使知道真实规律也无法消除的噪声。

Plug-in 思想：先估计 η 或 $\mathbb{E}[Y \mid X = x]$，再代入最优决策规则。它与“直接在 $\mathcal{H}$ 上最小化误差”的 ERM 是两条不同路线。

5. 为什么能泛化？

泛化间隙

$$\Delta(h) = |E_{\text{in}}(h) - E_{\text{out}}(h)|.$$

固定一个 h 时，Hoeffding 型结论给出

$$P\{\Delta(h) > \epsilon\} \leq 2e^{-2N\epsilon^2}.$$

但学习后的 $\hat{h}$ 是看过数据才选的，必须同时控制整个 $\mathcal{H}$。有限 $|\mathcal{H}| = M$ 时用 union bound：

$$P\{\exists h : \Delta(h) > \epsilon\} \leq 2Me^{-2N\epsilon^2}.$$

$\Rightarrow$ 样本越多，间隙缩小；候选规则越多，挑中“偶然好看”的规则越容易。

无限假设集不能简单数元素，而要数它在 N 个点上能产生多少种标记。

- **Shatter coefficient** $S(\mathcal{H}, N)$：在任意 N 点上可产生的最大二分方式数。
- **VC 维** d_{VC}：能被 $\mathcal{H}$ 打碎（实现全部 2^N 种标记）的最大点数。
- $d_{VC} < \infty$ 意味着复杂度可控；典型样本复杂度随 $(d_{VC} + \log(1/\delta))/\epsilon^2$ 增长。

PAC：“大概率（$1 - \delta$）近似正确（误差至多 ϵ）”。有限 VC 维与二分类的 PAC 可学习性等价。

6. 两类误差与模型选择

超额误差 $\approx$ 逼近误差 + 估计误差

逼近误差：$\mathcal{H}$ 太受限，

估计误差：$\mathcal{H}$ 太灵活或数据少.

欠拟合：高训练误差、高测试误差，通常是模型太简单。**过拟合**：训练误差低而测试误差高，通常是复杂度相对样本量过大。

正确的数据分工

- 训练集：拟合参数；验证集/交叉验证：选择复杂度、超参数和模型。
- 测试集：最后一次、无偏地报告泛化表现；看完再改模型就已变成验证集。
- K 折交叉验证：轮流用一折验证、其余训练，平均验证误差；最终用选定设置在全部非测试数据上重训。

7. 参数模型：少量参数概括数据

参数模型 $\{p(\cdot \mid \theta) : \theta \in \Theta \subseteq \mathbb{R}^m\}$ 假定分布形状，只估计有限个参数。**似然**把观测数据固定、把参数当变量：

$$L(\theta) = \prod_{i=1}^N p(z_i \mid \theta),$$

$$\hat{\theta}_{ML} = \arg\max_\theta \log L(\theta).$$

逻辑回归令 $\eta(x) = \sigma(w^T x + w_0)$，$\sigma(s) = 1/(1+e^{-s})$。最大似然等价于最小化交叉熵；以 $1/2$ 为阈值后，边界仍是 $w^T x + w_0 = 0$。分数是 log-odds：

$$\log \frac{\eta(x)}{1 - \eta(x)} = w^T x + w_0.$$

系数 w_j 每增加 1 单位特征，使 odds 乘 e^{w_j}。

感知机 $h_w(x) = \text{sign}(w^T x + w_0)$；错分 (x_i, y_i) 时更新 $w \leftarrow w + y_i x_i$、$w_0 \leftarrow w_0 + y_i$。仅在线性可分时保证有限步收敛。

8. 非参数分类：用“附近”投票

统一形式：

$$\hat{\eta}(x) = \sum_i W_i(x) \mathbf{1}\{y_i = 1\},$$

$$W_i \geq 0, \qquad \sum_i W_i = 1.$$

规则	谁投票	平滑旋钮	小旋钮时
直方图	同一格	格宽 l	过拟合
kNN	最近 k 个	k	过拟合
核方法	所有人，随距离衰减	带宽 σ	过拟合

它们依赖**空间一致性**：近点标签更相似。特征尺度错误、无关特征多或维度很高时，“近”会失去意义（维数灾难）。训练几乎免费，预测较贵；平滑量必须用验证选择。

9. 树、森林与回归

决策树/CART：反复用“$x_j \leq \alpha$?”切分空间；选择使加权子节点**不纯度**下降最大的切分。常用

$$I_{\text{Gini}} = 2p(1 - p),$$
$$I_{\text{ent}} = -p \log p - (1 - p) \log(1 - p).$$

树易解释、无需缩放，但边界呈阶梯且对样本非常不稳定；深度、叶数、最小叶样本数控制复杂度。贪心长树**不是**全局 ERM。

Bagging：bootstrap 重采样，拟合多棵树并投票，主要降低方差。**随机森林**再让每次切分只看随机特征子集，以降低树之间相关性；牺牲可解释性换稳定性。

回归：最小二乘 $\min_\theta \sum_i (y_i - h(x_i; \theta))^2$ 就是平方损失 ERM。线性回归是“对参数线性”，可用非线性基函数 $\phi_j(x)$：$h(x) = \sum_j \theta_j \phi_j(x)$。核回归则用邻近 y_i 的加权平均。

正面一眼判断

先问：输出是标签、数值还是概率？再问：是在估计条件分布（plug-in），还是直接优化经验准则（ERM/贪心）？最后找复杂度旋钮：$|\mathcal{H}|$、VC 维、$k/\sigma/l$、树深、基函数阶数。

COMP3670 概念速查表 反面：向量、聚类与线性代数

形状先行：每一步先写维度，再做运算。

10. 向量：数据点的表示

$x = (x_1, \dots, x_d)^T \in \mathbb{R}^d$ 是有顺序的特征列表；顺序和单位都属于表示的一部分。

$$x + y = (x_j + y_j)_j, \qquad ax = (ax_j)_j,$$
$$x^T y = \sum_j x_j y_j.$$

范数衡量“大小”，并诱导距离 $d(x, y) = \|x - y\|$：

$$\|x\|_1 = \sum_j |x_j|, \qquad \|x\|_\infty = \max_j |x_j|,$$
$$\|x\|_2 = \sqrt{\sum_j x_j^2}.$$

欧氏内积给出 $x^T y = \|x\|_2 \|y\|_2 \cos\theta$；正交即 $x^T y = 0$。

尺度警告：距离会被数值范围大的特征支配。距离模型前通常要标准化；类别编码也不能随意当作有序距离。

11. K-Means：用质心压缩数据

给定 K 个簇，交替：

1. **分配**：每点归入最近质心；
2. **更新**：每个质心改为簇内均值。

目标是最小化簇内平方和（SSE）：

$$J = \sum_{k=1}^{K} \sum_{x_i \in C_k} \|x_i - \mu_k\|_2^2,$$
$$\mu_k = \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i.$$

每一步都不增大 J，有限种分配意味着算法终止；但只保证**局部最优**，结果依赖初始化。常用多次随机重启或 k-means++。

适合近似球状、方差和大小相近的簇；对离群点、非凸簇、尺度差异敏感。K 是复杂度选择，不应只看训练 SSE（K 增大时它必降）。

12. 层次聚类：合并历史也是结果

凝聚式算法从单点簇开始，每步合并距离最近的两簇，直到只剩一个。**linkage** 定义簇间距离：

$$d_{\text{single}}(A, B) = \min_{a \in A, b \in B} d(a, b),$$
$$d_{\text{complete}}(A, B) = \max_{a \in A, b \in B} d(a, b).$$

single linkage 能找细长/非凸结构，但会“链化”；complete linkage 偏好紧凑、直径小的簇，对离群点敏感。

树状图 dendrogram 的高度是合并距离；在某高度横切得到聚类。它保留多尺度结构，无需预先固定 K，但距离与 linkage 的选择会改变答案。

13. 矩阵与线性映射

$A \in \mathbb{R}^{m \times d}$ 有 m 行、d 列。矩阵代表线性映射 $T : \mathbb{R}^d \to \mathbb{R}^m$：

$$T(x) = Ax,$$
$$A(\alpha x + \beta y) = \alpha Ax + \beta Ay.$$

两个互补视角：

$$Ax = \sum_{j=1}^{d} x_j a_j \quad \text{(列的线性组合)},$$
$$(Ax)_i = r_i^T x \quad \text{(每行做一次内积)}.$$

⇒ 列告诉你输出能由哪些方向组合；行告诉你每个输出坐标如何读取输入。

形状规则：$A_{m \times d} B_{d \times p} = C_{m \times p}$，内维必须相等。$AB$ 表示**先做 B，后做 A**；通常 $AB \neq BA$。

$$A(BC) = (AB)C,$$
$$A(B + C) = AB + AC,$$
$$AI = IA = A.$$

14. 转置、批处理与二次型

A^T 交换行列：$(A^T)_{ij} = A_{ji}$。

$$(A^T)^T = A, \qquad (A + B)^T = A^T + B^T,$$
$$(AB)^T = B^T A^T.$$

乘积转置**顺序反转**。若数据矩阵 $X \in \mathbb{R}^{N \times d}$ 每行是一个样本，则同时线性变换所有样本可写为 XA^T（取决于列/行样本约定，先验形状）。

最小二乘的矩阵形式：

$$L(w) = \|Xw - y\|_2^2$$
$$= (Xw - y)^T (Xw - y).$$

展开时标量满足 $y^T Xw = (Xw)^T y$，故交叉项合成 $-2y^T Xw$。

两层纯线性网络不会增加表达力：$A(Bx) = (AB)x$。若没有非线性激活，多层仍只是一个线性映射。

15. 线性方程组与消元

$Ax = b$ 等价于同时满足所有行方程，也等价于“b 是否能由 A 的列线性组合得到”。增广矩阵写作 $[A \mid b]$。

三种初等行操作（换行、非零倍缩放、一行加另一行倍数）都可逆，因此不改变解集。Gaussian elimination 得 REF；继续把主元化为 1 且清空主元列得到唯一的 RREF。

主元变量由方程决定；**自由变量**可任取参数。看 RREF 快速判断：

- 出现 $[0 \ \cdots \ 0 \mid c]$ 且 $c \neq 0$：无解；
- 一致且每个变量列都有主元：唯一解；
- 一致且有自由变量：无穷多解。

行操作用于保留方程解；列操作会改变变量意义，通常不能混用。

16. 逆矩阵：什么时候变换可撤销？

方阵 A 可逆若存在 A^{-1} 使 $A^{-1}A = AA^{-1} = I$。求逆可对 $[A \mid I]$ 行化简：若得到 $[I \mid B]$，则 $B = A^{-1}$。

等价判断（$A \in \mathbb{R}^{n \times n}$）：

- A 可逆；$Ax = b$ 对每个 b 有唯一解；
- $\text{RREF}(A) = I$；每行每列都有主元；
- 列向量线性无关且张成 $\mathbb{R}^n$；
- $\text{Null}(A) = \{0\}$；$\text{rank}(A) = n$。

$$(AB)^{-1} = B^{-1} A^{-1},$$
$$(A^T)^{-1} = (A^{-1})^T.$$

概念：逆不是“除以矩阵”，而是撤销线性变换；信息被压扁到更低维时便无法撤销。

17. Span、子空间、列空间与零空间

线性组合 $c_1 v_1 + \cdots + c_k v_k$；所有组合构成

$$\text{span}\{v_1, \dots, v_k\}.$$

子空间 $S \subseteq \mathbb{R}^n$ 必须含 0，且对加法、数乘封闭。检验常用：任取 $u, v \in S$ 与标量 a, b，证明 $au + bv \in S$。

对 $A = [a_1 \cdots a_d] \in \mathbb{R}^{m \times d}$：

$$\text{Col}(A) = \text{span}\{a_1, \dots, a_d\} \subseteq \mathbb{R}^m,$$
$$\text{Null}(A) = \{x : Ax = 0\} \subseteq \mathbb{R}^d.$$

⇒ $Ax = b$ 有解当且仅当 $b \in \text{Col}(A)$；零空间描述被 A 压成 0 的输入方向。

列空间基要取原矩阵的主元列；行化简后的主元列只告诉你索引，因为行操作会改变列空间。

18. 独立、基、维数、秩

$v_1, \dots, v_k$ **线性无关**若

$$c_1 v_1 + \cdots + c_k v_k = 0$$
$$\Rightarrow \ c_1 = \cdots = c_k = 0.$$

否则某向量可由其他向量组合，信息有冗余。把向量作列组成 V，求 $Vc = 0$：只有零解 $\Leftrightarrow$ 独立。

基 = “张成 + 独立”：既不缺方向，也无冗余。一个子空间的所有基含相同数量向量，称为**维数**。

秩是主元数，也是列空间维数；**零度**是自由变量数，也是零空间维数。对 $A \in \mathbb{R}^{m \times d}$：

$$\text{rank}(A) = \dim \text{Col}(A),$$
$$\text{nullity}(A) = \dim \text{Null}(A),$$

$$\boxed{\text{rank}(A) + \text{nullity}(A) = d}$$

上式即**秩–零度定理**。⇒ 每个输入方向要么贡献可见输出（秩），要么落入被消除的方向（零度）。

反面解题路线

向量/矩阵题先写形状；聚类题先确认距离与尺度；方程题做 RREF 看矛盾行和自由变量；空间题把“是否张成”化为 $Ax = b$，把“是否独立”化为 $Ax = 0$；最后用主元数和秩–零度定理互相校验。