COMP3670 机器学习速查 / MACHINE LEARNING

学习 / 统计 / 模型 / 聚类 / 标准正交几何

从数据学习 Learning from data

演绎 (Deduction)：理论 / 前提 → 预测；真前提加有效逻辑可保证结论。**归纳** (Induction)：观察 → 一般规律；有限证据不能证明普遍命题，一个反例就可将其**证伪** (falsify)。
监督学习 (Supervised)：有标签 (x_i, y_i)；分类输出离散，回归输出数值。**无监督** (Unsupervised)：只有 x_i，发现结构。**强化学习** (Reinforcement)：状态 → 动作 → 奖励，学习最大化累积奖励的策略（policy）；奖励可延迟。
感知机学习算法 (Perceptron learning algorithm, PLA)：$y_i \in \{-1, +1\}$。令 $w = b = 0$；找到错分点，更新，重复到无错分：

$$w \leftarrow w + y_i x_i, \qquad b \leftarrow b + y_i.$$

L1 约定 $w^T x + b > 0$ 判 $+1$，否则 -1。严格线性可分时有限步停止；不可分时无此保证。训练零错误不等于**泛化** (generalization) 良好。

方差与数值积分 Variance & integration

$$\mathrm{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2.$$

求 $I = \int_a^b f(x)dx$，记 $h = (b-a)/n$、$x_i = a + ih$、$f_i = f(x_i)$。
复合梯形公式 (Trapezoidal rule)

$$T_n = \frac{h}{2}\left[f_0 + 2\sum_{i=1}^{n-1} f_i + f_n\right].$$

若 $\max_{[a,b]} |f''| \le M_2$，则

$$|I - T_n| \le \frac{M_2(b-a)^3}{12n^2}.$$

复合辛普森公式 (Simpson's rule)：n 为偶数；内点权重按奇、偶索引取 $4, 2$。

$$S_n = \frac{h}{3}\left[f_0 + 4\sum_{\substack{1\le i<n \\ i \text{ odd}}} f_i + 2\sum_{\substack{2\le i<n \\ i \text{ even}}} f_i + f_n\right].$$

若 $\max |f^{(4)}| \le M_4$，则 $|I - S_n| \le M_4(b-a)^5/(180n^4)$。$n$ 加倍，梯形 / Simpson 误差界分别缩为 $1/4$、$1/16$。

泛化与复杂度 Generalization

$D = \{(X_i, Y_i)\}_{i=1}^N$ 独立同分布 (i.i.d.)；$L = E_{out}$ 为总体风险，$\widehat{L} = E_{in}$ 为经验风险；ERM 最小化 $\widehat{L}$。以下界用于二元 0–1 损失。
Hoeffding 不等式：h 须在看数据前固定。

$$\Pr\{|L(h) - \widehat{L}(h)| > \epsilon\} \le 2e^{-2N\epsilon^2}.$$

有限集合 $|\mathcal{H}| = M$，用**并集界** (union bound)：

$$\Pr\{\sup_h |L(h) - \widehat{L}(h)| > \epsilon\} \le 2Me^{-2N\epsilon^2}.$$

以至少 $1-\delta$ 的概率，所有 h 同时满足 $L(h) \le \widehat{L}(h) + \sqrt{\log(2M/\delta)/(2N)}$。数据选出的规则需要这种一致控制（uniform control）。
打散 (Shatter)：存在一个 N 点集，其全部 2^N 标记均可实现。$S(\mathcal{H}, N)$ 是最多可实现标记数；$v = d_{VC}$ 是最大可打散规模。单向阈值 VC 维为 1；区间为 2；$\mathbb{R}^d$ 中仿射超平面为 $d+1$。
Sauer 引理：有限 v、$N > v$ 时，$S(\mathcal{H}, N) \le (N+1)^v$。课件 VC 泛化界：

$$\Pr\{\sup_h |L - \widehat{L}| > \epsilon\} \le 8(N+1)^v e^{-N\epsilon^2/32}.$$

复杂度罚项为 $\sqrt{\frac{32}{N}[v\log(N+1) + \log(8/\delta)]}$。
不可知 PAC (Agnostic PAC)：对任意分布 P，当 $N \ge N_{\mathcal{H}}(\epsilon, \delta)$，要求 $\Pr\{L(\hat{h}) \le L(h^*) + \epsilon\} \ge 1 - \delta$，其中 $h^* = \arg\min_{h\in\mathcal{H}} L(h)$。二元分布无关 PAC 可学习 $\Leftrightarrow v < \infty$（标准可测性条件下）。课件界给出的充分样本量级：

$$N_{\mathcal{H}} = O\left(\frac{v\log(1/\epsilon) + \log(1/\delta)}{\epsilon^2}\right).$$

逼近 / 估计误差 (Approximation / estimation)

$$\underbrace{L(\hat{h}) - L(f^*)}_{\text{Bayes 超额风险}} = \underbrace{L(h^*) - L(f^*)}_{\Delta_{app}} + \underbrace{L(\hat{h}) - L(h^*)}_{\Delta_{est}}.$$

Δ_{app} 来自模型集合限制；Δ_{est} 来自有限数据。缩小集合可增加逼近误差，却降低估计难度；与偏差 / 方差权衡 (bias–variance trade-off) 有关。
K **折交叉验证** (Cross-validation, CV)：每次以 $K-1$ 折训练、剩余一折验证，轮换取平均：

$$E_{CV}(M) = K^{-1}\sum_{j=1}^{K} E_{val}^{(j)}(M).$$

按 CV 选超参数后，在开发数据上重拟合；未触碰的测试集只作最终评价。预处理也应在每折内拟合。折间分数不独立；获胜候选的 CV 分数仍可能乐观。

参数估计与逻辑模型 Parametric models

参数方法 (Parametric)：固定有限维模型族。**非参数** (Nonparametric)：复杂度可随数据增长，以局部性 / 平滑代替固定形状。**代入法** (Plug-in)：先估计条件概率 η，再代入决策规则。
似然（Likelihood）与最大似然估计 (Maximum likelihood estimation, MLE)，i.i.d.：

$$\mathcal{L}(\theta) = \prod_{i=1}^N p(z_i \mid \theta),$$

$$\hat{\theta} = \arg\max_\theta \sum_i \log p(z_i \mid \theta).$$

数据固定，参数变化；似然不是参数的概率分布。Bernoulli 模型 $\hat{p} = k/N$；高斯（Gaussian）MLE：

$$\hat{\mu} = N^{-1}\sum_i z_i, \qquad \hat{\sigma}^2 = N^{-1}\sum_i (z_i - \hat{\mu})^2.$$

一致性 / 渐近效率要求模型正确及正则条件；错误模型族即使拟合很好，也可能系统性偏离真实规律。
逻辑回归 (Logistic regression)，$y \in \{0, 1\}$：

$$g = w^T x + b, \quad p = \sigma(g) = \frac{1}{1+e^{-g}},$$

$$\log\frac{p}{1-p} = g.$$

几率 (odds)$= p/(1-p) = e^g$，g 是对数**几率** (log-odds)。其余变量固定，x_j 加一使 odds 乘 e^{w_j}，不是使概率乘该倍数。$p > 1/2 \iff g > 0$；代价可改变阈值。
交叉熵 (Cross-entropy, CE)

$$\ell_{CE}(y, p) = -y\log p - (1-y)\log(1-p).$$

条件似然 $\prod_i p_i^{y_i}(1-p_i)^{1-y_i}$；MLE 等价最小化平均 CE，并非直接最小化 0–1 错误。自信且错误的概率惩罚很大。
逻辑回归梯度 (Gradient)：增广 x 含偏置。

$$\sigma'(z) = \sigma(z)(1-\sigma(z)),$$

$$\nabla_w \ell_i = (\sigma(w^T x_i) - y_i)x_i,$$

平均梯度与 Hessian 公式见背面。

非参数分类 Nonparametric classification

直方图密度 (Histogram density)：一维箱 $A(x)$ 宽度为 l：

$$\hat{f}(x) = \frac{\#\{i : X_i \in A(x)\}}{Nl}.$$

d 维时分母中的 l 换为箱体积。**核密度估计** (Kernel density estimation, KDE)：核 κ 已归一化，带宽（bandwidth）为 σ。

$$\hat{f}(x) = \frac{1}{N\sigma^d}\sum_i \kappa\left(\frac{x - X_i}{\sigma}\right).$$

小箱宽 / 带宽：高方差、易过拟合；大带宽：更平滑、偏差增大。量纲、无关特征和高维稀疏性都会影响距离。
统一局部投票 (Local vote)：$W_i \ge 0$，$\sum_i W_i = 1$。

$$\hat{\eta}(x) = \sum_i W_i(x)\mathbf{1}\{Y_i = 1\},$$

$$\hat{h}(x) = \mathbf{1}\{\hat{\eta}(x) > 1/2\}.$$

直方图分类：$W_i = \mathbf{1}\{X_i \in A(x)\}/N(x)$，空箱须另定规则。$k$ **近邻** (kNN)：最近 k 点各权重 $1/k$，其余为零；小 k 更灵活、噪声更大。奇数 k 避免二元票数平局，不能避免距离并列。
核分类 (Kernel classification)

$$\text{Kernel:} \quad W_i(x) = \frac{\kappa((x - X_i)/\sigma)}{\sum_j \kappa((x - X_j)/\sigma)}.$$

紧支撑核须处理分母为零。**高斯核** (Gaussian)$e^{-\|u\|^2}$；**柯西核** (Cauchy)$(1+\|u\|^{d+1})^{-1}$；**均匀核** (Uniform)$\mathbf{1}_{\|u\|\le 1}$；**三角核** (Triangular)$(1-\|u\|)_+$；**Epanechnikov 核**$(1-\|u\|^2)_+$。共同常数在权重归一化时抵消。k, l, σ 用验证 / CV 选择。

决策树与不纯度 Trees & impurity

CART：递归问 $x_j \le a$，叶子构成轴对齐区域，各叶输出多数类。路径条件取 AND，同类叶子取 OR。
节点 R 内类别 1 比例为 p；Gini / 误分类 / 熵不纯度：

$$I_G = 2p(1-p), \quad I_{err} = \min(p, 1-p),$$

$$I_H = -p\log p - (1-p)\log(1-p), \quad 0\log 0 = 0.$$

纯节点不纯度为 0；$p = 1/2$ 时最大。**不纯度下降** (Impurity decrease)：

$$\Delta I = I(R) - \frac{N_L}{N_R}I(R_L) - \frac{N_U}{N_R}I(R_U).$$

N_R 是父节点人数，N_L, N_U 为两子节点人数。选合法候选中下降最大的分裂，再递归。**贪心** (greedy) 局部最优不等于树空间全局 ERM。按纯度、深度、最小叶人数停止，或**剪枝** (pruning)；用验证选约束。深单树方差高；严格单调变换保持可实现的阈值划分，排序可反向。

K 均值聚类 K-means

非空簇 $C_1, \ldots, C_k$ 的目标为簇内平方和（SSE）：

$$J = \sum_{r=1}^k \sum_{i\in C_r} \|x_i - c_r\|^2, \qquad c_r = \frac{1}{|C_r|}\sum_{i\in C_r} x_i.$$

Lloyd 步骤：初始化中心 / 划分；把每点分到最近中心；重新计算均值；重复到分配不变。多次初始化择优，可能收敛到不同局部最优。

$$\sum_i \|x_i - c\|^2 = \sum_i \|x_i - \bar{x}\|^2 + n\|c - \bar{x}\|^2.$$

此恒等式说明均值唯一最小化非空簇 SSE。分配和均值更新均不增加 J。若始终无空簇、距离并列时留在原簇，则每次分组改变严格降低 J；划分数量有限，故有限步停止，**不保证全局最优**。
空簇 (Empty cluster)：均值未定义，不能除以零。可重置中心（如选远点），或按预定策略保留旧中心。上面的终止证明假设非空；修复策略须另外考虑。特征缩放会改变聚类几何。

层次聚类 Hierarchical clustering

凝聚式 (Agglomerative)：从单点簇出发，按连接距离 (linkage) 合并最近两簇，记录合并高度，直至剩一簇。
单连接 (Single linkage)：最小跨簇距离。

$$d_{single}(A, B) = \min_{x\in A, y\in B} d(x, y),$$

全连接 (Complete linkage)：最大跨簇距离。

$$d_{complete}(A, B) = \max_{x\in A, y\in B} d(x, y),$$

平均连接 (Average linkage)：所有跨簇点对平均。

$$d_{average}(A, B) = \frac{1}{|A||B|}\sum_{x\in A}\sum_{y\in B} d(x, y).$$

Single 易经桥接点形成链（chaining）；Complete 偏向紧凑簇；Average 综合全部点对。**树状图** (Dendrogram) 的纵轴为合并不相似度；水平切线下的连通分支给出各簇。横向间隔不代表距离。同一切高下，不同 linkage 可给不同划分。

标准正交几何 Orthonormal geometry

柯西-施瓦茨不等式 (Cauchy–Schwarz)

$$|x^T y| \le \|x\|\|y\|.$$

等号当且仅当向量线性相关（含零向量情形）。证明用 $0 \le \|x - ay\|^2$，当 $y \ne 0$ 取 $a = x^T y/\|y\|^2$。
标准正交组 (Orthonormal list)：$q_i^T q_j = \delta_{ij}$，故线性无关；若张成 S，就是其标准正交基。令 $Q = [q_1 \cdots q_k]$：

$$Q^T Q = I_k, \qquad [x]_{\mathcal{Q}} = Q^T x \quad (x \in S).$$

用点积直接提取系数。矩形 Q 通常不满足 $QQ^T = I_d$。
正交矩阵 (Orthogonal matrix)特指方阵：

$$Q^{-1} = Q^T, \quad (Qx)^T(Qy) = x^T y, \quad \|Qx\| = \|x\|.$$

保持长度、距离、点积及非零向量夹角。不要把“列标准正交”直接当作“方形正交矩阵”。
Gram–Schmidt 正交化：输入 $v_1, \ldots, v_k$ 线性无关。

$$u_1 = v_1, \quad q_1 = u_1/\|u_1\|,$$

$$u_j = v_j - \sum_{i<j}(q_i^T v_j)q_i, \qquad q_j = u_j/\|u_j\|.$$

先减去全部已有方向的分量，再归一化；每个前缀的张成空间不变。残差为零表示相关，应跳过该向量，不可归一化零向量；最后核对 $Q^T Q = I$。

谱定理与半正定 Spectral theorem & PSD

实对称 $A = A^T \in \mathbb{R}^{d\times d}$ 有实标准正交特征基：

$$Aq_j = \lambda_j q_j, \quad Q^T Q = I,$$

$$A = Q\Lambda Q^T = \sum_{j=1}^d \lambda_j q_j q_j^T.$$

不同特征值的特征向量正交；重特征空间内可另选标准正交基。Q^T 取坐标，Λ 逐项伸缩，Q 转回原表示。

$$x = \sum_j a_j q_j \quad \Rightarrow \quad x^T Ax = \sum_j \lambda_j a_j^2.$$

半正定 (Positive semidefinite, PSD)：$A \succeq 0 \iff$ 对所有 x 有 $x^T Ax \ge 0 \iff$ 全部 $\lambda_j \ge 0$。**正定** (Positive definite, PD)：对非零 x 严格为正，等价全部 $\lambda_j > 0$。
PSD 可奇异，PD 可逆。任意实 B 均有 $B^T B \succeq 0$，因为 $x^T B^T Bx = \|Bx\|^2$。有负特征值则非 PSD。一般非对称实矩阵未必有正交实特征基。

支持向量机 SVM

SVM：Support vector machine。$y_i \in \{-1,+1\}$，分数 $f_i = w^T x_i + b$。本节 $f \geq 0$ 判 $+1$，否则 -1；$w \neq 0$ 时函数间隔 / 几何间隔 / 点到边界距离为：

$$m_i = y_i f_i, \quad \gamma_i = \frac{m_i}{\|w\|}, \quad d(x,H) = \frac{|w^T x + b|}{\|w\|}.$$

正比例缩放参数不改变边界与几何间隔，但改变原始分数。

硬间隔 (Hard margin)：两类均出现、严格可分。

$$\min_{w,b} \tfrac{1}{2}\|w\|^2 \quad \text{s.t. } m_i \geq 1 \ (\forall i).$$

最优解 $\min_i m_i = 1$；训练间隔 $\gamma = 1/\|w\|$，完整间隔带宽 $2/\|w\|$。**支持向量** (Support vectors)满足 $m_i = 1$，触及间隔边界。

软间隔 (Soft margin)：$C > 0$；**松弛变量** (slack)$\xi_i \geq 0$ 允许违反单位间隔。

$$\min_{w,b,\xi} \quad \tfrac{1}{2}\|w\|^2 + C\sum_i \xi_i,$$
$$\text{s.t.} \quad m_i \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

固定 w, b，最小松弛 $\xi_i^* = (1-m_i)_+ = \max(0, 1-m_i)$，即合页损失 (hinge loss)。等价目标：

$$J(w,b) = \tfrac{1}{2}\|w\|^2 + C\sum_i (1-m_i)_+.$$

$\xi = 0$ 满足间隔；$0 < \xi < 1$ 在正确侧但侵入间隔；$\xi = 1$ 在决策边界；$\xi > 1$ 在错误侧。分对也可有 hinge 损失；软 SVM 中间隔内 / 违规点也可影响拟合。

大 C 更重罚违反，小 C 更偏好小范数。单位 / 尺度 (scale)改变距离与正则化几何，应联同 C 调整。软间隔允许 $w = 0$，此时是常数打分。

二次规划 (Quadratic programming, QP)：凸二次目标加线性约束，局部极小均为全局极小。

次梯度 (Subgradient)：先由同一组旧参数计算 $I = \{i : m_i < 1\}$，再同时更新：

$$w^+ = (1-\eta)w + \eta C \sum_{i \in I} y_i x_i,$$
$$b^+ = b + \eta C \sum_{i \in I} y_i.$$

收缩权重并修正违规点；$m = 1$ 处取零 hinge 次梯度合法。单步可增加目标，任意常步长不保证收敛。

非线性 SVM (Nonlinear SVM)：固定特征映射（feature map）ϕ，在分数、损失和更新中将 x_i 换为 $\phi(x_i)$。对参数仍凸，原空间边界可弯曲。例：$\phi(x) = (x, x^2)$，$4x - x^2 - 3 > 0 \iff 1 < x < 3$；特征 $x_1^2 + x_2^2$ 可表达圆边界。

奇异值分解与推荐 SVD & recommendation

SVD：Singular value decomposition。$A \in \mathbb{R}^{m \times d}$，秩 r，**紧 SVD** (Compact SVD)：

$$A = U_r \Sigma_r V_r^T = \sum_{j=1}^{r} \sigma_j u_j v_j^T,$$

$U_r \in \mathbb{R}^{m \times r}$、$V_r \in \mathbb{R}^{d \times r}$ 各列标准正交；奇异值 $\sigma_1 \geq \cdots \geq \sigma_r > 0$。

$$Av_j = \sigma_j u_j, \quad A^T u_j = \sigma_j v_j, \quad A^T A v_j = \sigma_j^2 v_j.$$

截断 (Truncation)：$A_k = U_k \Sigma_k V_k^T$ 在秩至多 k 的矩阵中最小化 Frobenius 平方误差：

$$\|A - A_k\|_F^2 = \sum_{j>k} \sigma_j^2, \quad \|A\|_F^2 = \sum_j \sigma_j^2.$$

推荐因子 (Latent factors)：评分表 $R \in \mathbb{R}^{n \times m}$，用户因子 $P \in \mathbb{R}^{n \times k}$，物品因子 $Q \in \mathbb{R}^{m \times k}$；$\hat{r}_{ij} = p_i^T q_j$、$\hat{R} = PQ^T$。完整表可取 $P = U_k \Sigma_k, Q = V_k$。行是单个对象的嵌入（embedding），列是模式。

缺失评分 (Missing ratings)不等于零；只拟合已观察训练对 Ω：

$$L = \sum_{(i,j)\in\Omega} (r_{ij} - p_i^T q_j)^2 + \lambda(\|P\|_F^2 + \|Q\|_F^2).$$

交替最小二乘 (Alternating least squares, ALS)：$\lambda > 0$，小随机值初始化，交替解岭回归。Q_i 含用户 i 评过的物品行，r_i 是对应评分；P_j 含给物品 j 评分的用户行，评分为 r_j：

$$p_i = (Q_i^T Q_i + \lambda I)^{-1} Q_i^T r_i,$$
$$q_j = (P_j^T P_j + \lambda I)^{-1} P_j^T r_j.$$

求解线性系统，不显式求逆。精确块更新不增加 L；联合问题非凸，无全局保证。用验证选 k, λ；独立测试评分评价预测。无训练记录称**冷启动** (cold start)。

$$\text{RMSE} = \sqrt{\frac{1}{|T|}\sum_{(i,j)\in T} (r_{ij} - \hat{r}_{ij})^2}.$$

RMSE 为**均方根误差** (Root mean squared error)。

二阶检验与凸性 Second-order tests

一维驻点 (Stationary point)：可微内点极值须有 $f'(x^*) = 0$，但零导数不充分。$f''(x^*) > 0$ 为严格局部极小，< 0 为严格局部极大，$= 0$ 无法判定；还要检查端点与不可微点。

多变量：$\nabla f(x^*) = 0$；**海森矩阵** (Hessian)$H_{ij} = \partial_i \partial_j f$，$C^2$ 时对称。

$$f(x+v) \approx f(x) + \nabla f(x)^T v + \tfrac{1}{2} v^T H(x) v.$$

在驻点：$H \succ 0$ 为严格局部极小；$H \prec 0$ 为严格局部极大；不定（indefinite）为**鞍点** (saddle)；半正 / 半负定的奇异情形检验不充分。C^2 的局部极小必要条件是 $H \succeq 0$。

二维判别式：$D = f_{xx} f_{yy} - f_{xy}^2$。驻点处 $D > 0, f_{xx} > 0$ 为极小；$D > 0, f_{xx} < 0$ 为极大；$D < 0$ 为鞍点；$D = 0$ 无法判定。

凸性 (Convexity)：定义域为凸集。

$$f(tx + (1-t)y) \leq tf(x) + (1-t)f(y), \quad t \in [0,1].$$

可微时等价 $f(y) \geq f(x) + \nabla f(x)^T (y - x)$；$C^2$ 时等价处处 $H(x) \succeq 0$。凸函数局部极小即全局极小，$\nabla f = 0$ 足以判定全局最小。**严格凸** (strictly convex)至多一个最小点，但不保证存在。处处 $H \succ 0$ 是严格凸的充分非必要条件。

正规方程与 Ridge Normal equations

设计矩阵 $X \in \mathbb{R}^{N \times p}$ 的行可含截距 / 基函数，$y \in \mathbb{R}^N$。

残差平方和 (RSS)：

$$RSS = \|X\theta - y\|^2, \quad \nabla RSS = 2X^T(X\theta - y),$$
$$\nabla^2 RSS = 2X^T X \succeq 0, \qquad X^T X \hat{\theta} = X^T y.$$

若 X 满列秩（full column rank）：

$$\hat{\theta} = (X^T X)^{-1} X^T y.$$

否则最小化参数可不唯一，但训练拟合值唯一。数值实现应解最小二乘，而非显式求逆。

岭回归 (Ridge regression)：$\lambda > 0$。

$$J = RSS + \lambda\|\theta\|^2, \quad \hat{\theta} = (X^T X + \lambda I)^{-1} X^T y,$$
$$\nabla J = 2X^T(X\theta - y) + 2\lambda\theta.$$

$X^T X + \lambda I \succ 0$，保证唯一解并改善条件数 (conditioning)。上式惩罚所有参数；若不惩罚截距，将 I 换为 $\text{diag}(0, 1, \ldots, 1)$，唯一性需另核条件。

参数回归 (Parametric regression)：$h_\theta(x) = \sum_j \theta_j \phi_j(x)$ 对参数线性，关于输入可非线性。平方损失最优为 $f^*(x) = \mathbb{E}[Y \mid X = x]$。**核 / kNN 回归**：$\hat{h}(x) = \sum_i W_i(x) Y_i$；用归一化核权重，或最近 k 个输出均值。**回归树** (Regression tree)：叶子预测均值，按子节点 RSS 选分裂；森林取树预测平均。

逻辑回归的平均梯度与 Hessian：

$$\nabla J = \frac{1}{N}\sum_i (p_i - y_i) x_i, \qquad \nabla^2 J = \frac{1}{N} X^T D X,$$

$D = \text{diag}(p_i(1-p_i)) \succeq 0$，故目标凸，通常无闭式解。无正则且数据可分时，有限参数 MLE 可能不存在。

梯度下降与收敛 GD & convergence

$$\theta_{t+1} = \theta_t - \alpha \nabla J(\theta_t).$$

全批量梯度下降（GD）每步用全部 N 点。$J = RSS/N$ 时：

$$\theta^+ = \theta - \alpha \frac{2}{N} X^T (X\theta - y).$$

学习率 (Learning rate)α 太大会振荡 / 发散，太小则慢。梯度小、目标 / 参数变化小或达到迭代预算可停止；验证可指导**早停** (early stopping)。

若凸目标 K-光滑（smooth）、最小点存在，且 $0 < \alpha \leq 1/K$：

$$J(\theta_t) - J(\theta^*) \leq \frac{\|\theta_0 - \theta^*\|^2}{2\alpha t}.$$

K 是 Hessian 特征值上界 / 梯度 Lipschitz 常数。强凸 (strongly convex)、曲率下界 $\mu > 0$ 时，适当 GD 有线性速率；非凸时不保证全局最小。

随机 / 小批量梯度 (SGD / mini-batch)，$J = N^{-1}\sum_i \ell_i$：

$$g_t = \frac{1}{b}\sum_{i \in B_t} \nabla \ell_i(\theta_t), \quad \theta_{t+1} = \theta_t - \alpha_t g_t.$$

均匀抽样时 $\mathbb{E}[g_t \mid \theta_t] = \nabla J(\theta_t)$。一轮（epoch）约 N/b 次更新。小 b 每步便宜、噪声大；大 b 方差小、代价高。正则项梯度另加，注意平均与求和的尺度。

固定学习率常留下噪声平台（noise floor）。标准随机逼近条件下，一组充分的递减步长条件为：

$$\sum_t \alpha_t = \infty, \qquad \sum_t \alpha_t^2 < \infty.$$

例如 $\alpha_t = a/(b+t)^\gamma$、$1/2 < \gamma \leq 1$。仍须满足目标与梯度噪声等假设，不能仅凭步长序列宣称收敛。

集成学习 Ensemble learning

装袋 (Bagging)：有放回重采样（bootstrap）B 次，每份大小 N，各拟合一棵树。分类多数投票，回归平均；成员相关性越低，降方差通常越有效。

随机森林 (Random forest)：bootstrap 加每次分裂随机抽特征子集，常使用深树。随机特征降低树间相关性，增强稳定性但牺牲可解释性；不保证绝不过拟合。

神经网络与反传 Neural networks

前向传播 (Forward pass)：$a^0 = x$；隐藏层：

$$z^\ell = W^\ell a^{\ell-1} + b^\ell, \qquad a^\ell = \phi(z^\ell).$$

无非线性激活时，多层仿射映射仍可合成一层。训练通常非凸；表达能力强不保证泛化。

激活函数 (Activations)：整流线性单元 ReLU 为 $(z)_+ = \max(0, z)$；sigmoid 为 $\sigma(z) = 1/(1+e^{-z})$；双曲正切 tanh z；反正切 arctan z；阶跃（step）$\mathbf{1}\{z \geq 0\}$。

$$\phi'_{ReLU} = \mathbf{1}\{z > 0\} \ (z \neq 0), \quad \sigma' = \sigma(1-\sigma),$$
$$(\tanh z)' = 1 - \tanh^2 z, \quad (\arctan z)' = (1+z^2)^{-1}.$$

ReLU 在零点可选次梯度（常取 0）；阶跃跳点无普通导数，其他点梯度为零，不利于梯度训练。

输出层 (Output)：二元用 sigmoid + BCE；多类用 softmax + CE，y 为独热（one-hot）标签：

$$p_c = \frac{e^{z_c}}{\sum_j e^{z_j}}, \quad \hat{y} = \arg\max_c p_c,$$
$$\ell = -\sum_c y_c \log p_c.$$

指数运算前减去 $\max_j z_j$ 可提高数值稳定性。上述匹配输出 / 损失组合的输出误差均为 $\delta^L = p - y$。

反向传播 (Backpropagation)：输出分数 logits 为线性层，隐藏层误差逐层回传：

$$\delta^\ell = ((W^{\ell+1})^T \delta^{\ell+1}) \odot \phi'(z^\ell),$$
$$\frac{\partial \ell}{\partial W^\ell} = \delta^\ell (a^{\ell-1})^T, \qquad \frac{\partial \ell}{\partial b^\ell} = \delta^\ell.$$

平均损失须取各样本梯度平均。链式法则（chain rule）传误差，注意形状匹配；饱和激活可导致小梯度。

初始化 (Initialization)：零均值小随机权重打破神经元对称性；偏置可取零。输入 / 输出连接数为 fan-in n_{in}、fan-out n_{out}，常用**权重方差**（不是标准差）：

$$\text{LeCun } \frac{1}{n_{in}}, \quad \text{Xavier } \frac{2}{n_{in}+n_{out}}, \quad \text{He } \frac{2}{n_{in}}.$$

He 适合 ReLU；Xavier 平衡层间尺度。隐藏权重全零会使同层单元保持对称。

优化器更新式 Optimizer equations

$g_t = \nabla J(w_t)$ 或小批量梯度。平方、开根、乘除均逐坐标 (elementwise)；历史状态初始为零。$0 < \beta, \beta_1, \beta_2 < 1$，$\epsilon > 0$ 防止数值除零。

动量 / 重球 (Momentum / heavy ball)：采用速度（velocity）记法。

$$v_t = \beta v_{t-1} - \alpha_t g_t, \qquad w_{t+1} = w_t + v_t.$$

积累历史下降方向，可减少振荡。

Nesterov 加速梯度 (NAG)：在前瞻（look-ahead）位置计算梯度。

$$v_t = \beta v_{t-1} - \alpha_t \nabla J(w_t + \beta v_{t-1}),$$
$$w_{t+1} = w_t + v_t.$$

与 heavy ball 的差异在梯度求值位置。

自适应梯度 (Adagrad)：永久累计历史梯度平方。

$$s_t = s_{t-1} + g_t \odot g_t, \qquad w_{t+1} = w_t - \frac{\alpha_t g_t}{\sqrt{s_t + \epsilon}}.$$

按坐标缩小有效学习率，对稀疏坐标有用，但步长可能持续变小。

均方根传播 (RMSProp)：以指数移动平均（EMA）替代永久累计。

$$s_t = \beta s_{t-1} + (1-\beta) g_t \odot g_t,$$
$$w_{t+1} = w_t - \frac{\alpha_t g_t}{\sqrt{s_t + \epsilon}}.$$

遗忘旧平方梯度。本课 Adagrad、RMSProp 的 ϵ 放在根号内。

自适应矩估计 (Adaptive moment estimation, Adam)：沿用课件的负梯度一阶矩。

$$m_t = \beta_1 m_{t-1} - (1-\beta_1) g_t,$$
$$s_t = \beta_2 s_{t-1} + (1-\beta_2) g_t \odot g_t,$$
$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \qquad \hat{s}_t = \frac{s_t}{1-\beta_2^t}, \qquad t \geq 1,$$
$$w_{t+1} = w_t + \frac{\alpha_t \hat{m}_t}{\sqrt{\hat{s}_t + \epsilon_{root}} + \epsilon}.$$

$m_0 = s_0 = 0$；从 $t = 1$ 做**偏差修正** (bias correction)。常用 $\beta_1 = .9$、$\beta_2 = .999$、$\epsilon = 10^{-8}$、$\epsilon_{root} = 0$。

符号检查：负梯度已存在 m_t 中，所以最后用加号。若一阶矩改存正梯度，最后须用减号；不能混用。偏差修正补偿 EMA 从零开始的偏差，不是消除统计模型偏差。